

KABO：一种任务解耦的知识增强贝叶斯优化框架

及其在光催化 CO_2 还原中的应用

Jiayu Wu

2026 年 4 月 17 日

摘要

仿酶催化体系 (CO_2RR 、OER、NRR、ORR 等) 的实验寻优长期面临高维设计空间、昂贵实验成本和领域知识难以结构化注入三重障碍。本文提出并实现了一种**任务解耦的知识增强贝叶斯优化框架** (Task-decoupled Knowledge-Augmented Bayesian Optimization, KABO)，将纯数学优化能力封装为与体系无关的 **KABOEngine**，将体系相关逻辑抽象为统一的 **TaskBase** 接口。算法核心整合了偏好学习 (Preference Learning)、专家先验编码 (Expert Prior Encoding)、偏好探索子循环 (Preference Exploration) 与近似信息价值 (Approximate VOI) 四项知识内化机制，通过 z-score 标定的复合采集函数协同驱动候选选择。任务层以一个体系一个文件的形式组织 (`kabo/task/*.py`)，已内置光催化 CO_2 还原任务 (`CO2RRTask`, 19 描述符 / 7 产物) 与最小综合任务 (`TestTask`, 3 描述符 / 1 产物)。新增体系 (OER 等) 仅需新增一个约 50 行的 Task 类，Engine、Optimizer 与 CLI 零改动。本文以 CO_2RR 为主体案例，详述了架构分层、数学重构、KABO 四项机制、偏好探索子循环与人类在环闭环；并通过 `TestTask` 的端到端冒烟测试印证 Engine 的体系无关性。

关键词：贝叶斯优化；高斯过程；知识增强；偏好学习；任务解耦架构；光催化； CO_2 还原

目录

1 引言 (Introduction)

4

2 任务解耦的系统架构 (Task-Decoupled System Architecture)	4
2.1 分层职责	4
2.2 TaskBase 接口契约	5
2.3 注册机制与零改动扩展	6
3 描述符处理与边界感知归一化	7
3.1 非线性特征拆分及基尼重要度评判	7
3.2 缺失特征重构与”Pre-fill-before-choice” 机制	7
3.3 边界感知归一化 (Bounds-Aware Normalization)	7
4 高斯过程代理模型	7
4.1 ARD Matérn 核	7
4.2 超参数的边际对数似然估计	8
5 基础采集策略	8
5.1 UCB 与 β_t 调度	8
5.2 噪声下的 qNEI	9
6 知识增强贝叶斯优化 (KABO)	9
6.1 KABO 复合采集函数	9
6.2 偏好学习与蒙特卡洛效用积分	10
6.3 专家先验编码	10
6.4 近似信息价值 (Approximate VOI)	11
7 偏好探索子循环 (Preference Exploration)	11
8 多样性感知推荐菜单	11
9 人类在环机制与 KABO 执行流	12
10 案例研究：光催化 CO₂ 还原 (C02RRTask)	14
10.1 19 描述符 $\times$ 7 产物方案	14
10.2 HER 选择性复合目标	14
10.3 产物模拟分布 (Demo 模式)	14
11 体系无关性验证：TestTask	14
12 可追溯性与参数审计	15
13 讨论与展望	15
13.1 任务解耦的工程价值	15

13.2 潜在扩展方向	16
14 结语	16

1 引言 (Introduction)

仿酶催化体系——以光催化 CO_2 还原 (CO_2RR) 为代表——在通往化学品绿色合成的路径上具有战略价值 [7,8]，但其材料探索在工程上面临三重结构性困难：

1. **高维非凸设计空间**：催化剂性能受数十个描述符共同控制（能带间隙、 A_{pI} 、位点距离、溶剂偶极……），配方响应面高度非线性，全穷举与高通量筛选 (HTS) [8] 受制于“维数灾难”。
2. **昂贵实验评估函数**：单次光催化收率测量通常需要数小时到数天，实验预算难以支撑样本数 $N \gg$ 维度 d 的经典统计假设。
3. **领域知识的结构化注入缺失**：资深化学家的经验——“最优电位约 -0.8 V ”、“甲酸产物的选择性与亲水溶剂强相关”——长期停留在口头约定与手工试错，难以融入数学模型结构。

应对昂贵评估的经典范式是贝叶斯优化 (Bayesian Optimization, BO) [5]，其在黑盒函数导数不可得的条件下提供了理论严密的主动采样策略 [3,4]。然而标准 BO 与真实实验室之间仍存在两类鸿沟：其一，量纲悬殊导致核函数的欧氏度量坍塌 [4]；其二，专家直觉无法被代理模型结构性地“内化”。本报告在原始“人类在环”贝叶斯优化 (HITL-BO) 框架基础上，构建了 **KABO 知识增强贝叶斯优化体系**，并通过一层任务抽象使其天然支持多类催化体系。

KABO 将优化流程组织为四阶段：降维筛选 (Phase 1) $\rightarrow$ 高斯代理模型重建 (Phase 2) $\rightarrow$ 偏好探索与知识采集 (Phase 2.5) $\rightarrow$ 知识增强采集-交互闭环 (Phase 3)，并通过偏好学习 [9]、专家先验编码 [11] 及近似信息价值 [10] 三条路径实现知识的持久内化与循环利用。Task 抽象层则负责所有体系相关语义（特征、产物、边界、交互文案），使同一份算法内核可以驱动任意催化体系。

2 任务解耦的系统架构 (Task-Decoupled System Architecture)

2.1 分层职责

KABO 采用三层架构（图 1）将纯数学能力与体系语义彻底解耦：

- **算法层** `kabo.engine.KABOEngine`：聚合 `SurrogateModel` (GP 代理)、`PreferenceModel` (PairwiseGP 偏好学习)、`ExpertPrior` (专家先验打分)。接口仅接受数值矩阵、边界张量与特征列表，**不包含任何体系关键词**。

- **领域层** `kabo.task.TaskBase`: 抽象合同定义特征集合、设计域边界、产物列、训练目标构造、交互与模拟逻辑。每个体系以一个独立 Python 文件实现 (`kabo/task/co2rr.py`、`kabo/task/test_task.py` 等), 通过 `@register_task` 装饰器自动注册到全局任务表 `TASK_REGISTRY`。
- **编排层** `kabo.optimizer.KABOOptimizer`: 负责三阶段流程调度、离散/连续候选合并、Top-N 菜单呈现与审计字段写入。编排器持有一个 `task` 对象, 所有体系相关读操作均经由 `self.task.*` 委派。




图 1: KABO 三层架构：装配、编排、算法、领域各司其职。

2.2 TaskBase 接口契约

`TaskBase` 作为抽象基类定义了以下最小契约：

- `task_name()` → 体系短标识 ("CO2RR"、"OER")
- `feature_columns()` → 全量特征列名 (有序)
- `design_space_bounds()` → 每个特征的物理边界
- `target_columns()` → 产物短名 → DataFrame 列名映射
- `default_target()` → 默认优化目标

- `build_training_target(df, target_column, **kwargs)` → 代理模型训练向量构造（支持复合目标，如 CO_2RR 的 $Y_{\text{target}} - w \cdot Y_{H_2}$ ）
- `prompt_observation(target_column)` → 交互模式下收集实验观测
- `simulate_observation(target_column,  $\mu$ ,  $\sigma$ )` → 演示模式下模拟观测

可选 Hook (`validate_candidates`、`parse_expert_prior`) 提供默认实现。契约设计遵循“已知抽象、未知具体”原则：Engine 只向 Task 提出问题（“你的特征是什么？目标是什么？”），Task 的具体答案不渗漏回算法层。

2.3 注册机制与零改动扩展

新增体系的工作流具体化为三步：

Listing 1: 新增 OERTask 的最小模板

```

1 # kabo/task/oer.py
2 from kabo.task.base import TaskBase, register_task
3
4 @register_task
5 class OERTask(TaskBase):
6     def task_name(self): return "OER"
7     def feature_columns(self): return ["overpotential", "pH", ...]
8     def design_space_bounds(self):
9         return {"overpotential": (0.2, 1.2), "pH": (0.0, 14.0), ...}
10    def target_columns(self): return {"O2": "Y_O2"}
11    def default_target(self): return "O2"
12    def build_training_target(self, df, target_column, **kwargs):
13        return df[target_column].values.astype(float)
14    def prompt_observation(self, target_column): ...
15    def simulate_observation(self, target_column, y_mean, y_std):
    ...

```

随后在 `kabo/task/__init__.py` 追加一行 `from kabo.task.oer import OERTask` 以触发注册。用户立即可用 `python run.py --task oer`，**Engine、Optimizer、CLI 核心代码零改动**。这一约束由算法层模块的静态代码检查保证：对 `kabo/engine.py`、`kabo/acquisition.py`、`kabo/feature_selection.py` 等算法层文件执行 `grep` 扫描，不应出现任何体系特定常量。

3 描述符处理与边界感知归一化

3.1 非线性特征拆分及基尼重要度评判

原始数据集在 Task 声明的 d 维描述符空间中展开 (CO₂RR 为 19 维)。在可获取数据点数量有限 ($N \sim 20$)、局部信噪比低的条件下强行使用全维 GP 易导致过度平滑或局部震荡。系统前置随机森林非线性降维, 使用基尼重要度保留 Top- K 维:

$$\text{Imp}(x_j) = \frac{1}{N_{\text{trees}}} \sum_{t=1}^{N_{\text{trees}}} \sum_{s \in \text{nodes}(t), v(s)=x_j} p(s) \cdot \Delta I(s) \quad (1)$$

$\Delta I(s)$ 为基于特征 x_j 拆解引起的杂质 (方差) 下降, $p(s)$ 为节点权重。随机森林在 $N < 10$ 时自动降低 `n_estimators` 与深度以避免过拟合, 生成 $X_{\text{selected}} \in \mathbb{R}^{N \times K}$ 。相较于 PCA 带来的物理解释性丧失, 基尼度量保留了特征的可追溯性 [4]。

3.2 缺失特征重构与”Pre-fill-before-choice” 机制

得到最优连续点 $x_{\text{cont}}^* \in \mathbb{R}^K$ 后, 实验配方需恢复到 Task 声明的全部 d 维以满足合成可行性。架构引入 **Pre-fill-before-choice** 机制: 未被选中的 $d - K$ 维特征按专家预填值或设计域中点补齐, 使候选呈现给专家时已为完整配方, 避免描述符不完整导致的审核错位。

3.3 边界感知归一化 (Bounds-Aware Normalization)

传统机器学习常用 $\text{MinMax}(X_{\text{train}})$ 归一化, 但当模型探索超出训练样本极值范围时会产生灾难性失真。系统改用 Task 提供的理论设计域边界 $(l^{(k)}, u^{(k)})$ 做归一化:

$$x_{\text{norm},k} = \max \left(0, \min \left(1, \frac{x_k - l^{(k)}}{u^{(k)} - l^{(k)}} \right) \right) \quad (2)$$

此举确保高斯代理能够在训练样本未覆盖的区域无缝外推, 完全杜绝由训练集极值作为归一化分母引入的伪外推偏误。

4 高斯过程代理模型

4.1 ARD Matérn 核

利用观测 $\mathcal{D}_N = \{X_{\text{selected}}^{(i)}, y^{(i)}\}_{i=1}^N$ 构建代理模型 $f(x) \sim \mathcal{GP}(\mu, k(x, x'))$ 。化学体系内诸如功函数 (eV) 与比表面积 (m²/g) 的标度差异悬殊, 通用欧氏度量会坍塌。选择带自动关联性决定 (ARD) 的 Matérn 核, $\nu = 2.5$ 兼顾不可导的高频震荡:

$$k_{\text{Matérn } 2.5}(x, x') = \sigma_f^2 \left(1 + \sqrt{5}d_{\text{ARD}} + \frac{5}{3}d_{\text{ARD}}^2\right) \exp\left(-\sqrt{5}d_{\text{ARD}}\right) \quad (3)$$

加权对角矩阵对 K 维变量实现独立长度尺度缩放 l_k :

$$d_{\text{ARD}}(x, x') = \sqrt{\sum_{k=1}^K \frac{(x_k - x'_k)^2}{l_k^2}} \quad (4)$$

l_k 的自适应对特征量纲刚性错位实现有效补偿。对于更为复杂的形貌突变响应曲面，复合谱混合核 (Spectral Mixture Kernels) [6] 作为可选接口通过 `--kernel-type spectral_mixture` 启用。

4.2 超参数的边际对数似然估计

核方差 σ_f^2 、观测白噪声方差 σ_n^2 与尺度向量 $\mathbf{l}$ 通过最大化 Exact Marginal Log-Likelihood 获得:

$$\log p(\mathbf{y}|X, \boldsymbol{\theta}) = -\frac{1}{2}\mathbf{y}^\top (K_\theta + \sigma_n^2 I)^{-1} \mathbf{y} - \frac{1}{2} \log |K_\theta + \sigma_n^2 I| - \frac{N}{2} \log 2\pi \quad (5)$$

求解过程使用 L-BFGS-B 或基于 Torch 的梯度下降 (`fit_gpytorch_mll`)。

5 基础采集策略

高分辨收率测定常带有光源扰动或杂质吸附引入的环境噪声。系统融合了置信区间探索与带噪期望改进两类算法基准，统一封装在 `KABOEngine.build_acquisition(beta)` 接口下，通过 `--acq-strategy` 切换。

5.1 UCB 与 β_t 调度

依 Ding et al. [1] 的 GP-UCB 理论准则，最大化置信上边界在探索与收割之间给出黄金折中。本实现采用 BoTorch 常见参数化:

$$\alpha_{\text{UCB}}(x) = \mu_{t-1}(x) + \beta_t \sigma_{t-1}(x) \quad (6)$$

三种 β_t 调度模式:

- **fixed**: 常数 β , 默认 2.0
- **theory**: $\beta_t = \beta \cdot 2 \log(t^{d/2+2} \pi^2 / (3\delta))$, 允许用户 **beta** 缩放
- **theory-strict**: 纯理论 β_t (不做缩放), 用于高保真论文复现

5.2 噪声下的 qNEI

BoTorch 引擎底层的带噪期望提升 (qNoisyExpectedImprovement) 用 Monte Carlo 法整合观测概率提升 [2]:

$$\alpha_{\text{qNEI}}(x) = \mathbb{E}_{y|x \sim \mathcal{N}} [\max(y - y_{\text{best}}^*, 0)] \quad (7)$$

使用 128 采样数 (可调) 的 SobolQMCNormalSampler 做 Quasi-Monte Carlo 无偏估计 [3]。qNEI 对高噪声场景比 UCB 更稳健。

6 知识增强贝叶斯优化 (KABO)

标准 HITL-BO 中, 专家反馈仅体现为单次候选选择, 其蕴含的偏好模式和领域知识未被结构性沉淀。KABO 通过三条知识通道注入结构化先验。

6.1 KABO 复合采集函数

KABO 核心是一个四项加权组合采集函数。为防止各项因量纲与数值范围差异导致的信号压制, 在组合前对每一项做**在线 z-score 标准化**:

$$\alpha_{\text{KABO}}(x) = z(\alpha_{\text{base}}(x)) + \lambda_p \cdot z(\text{Pref}_{\text{MC}}(x)) + \lambda_k \cdot z(\text{Prior}(x)) + \lambda_v \cdot z(\text{VOI}(x)) \quad (8)$$

z-score 定义为:

$$z(t) = \frac{t - \bar{t}}{\hat{\sigma}_t + \epsilon}, \quad \hat{\sigma}_t = \sqrt{\frac{1}{n} \sum_{i=1}^n (t_i - \bar{t})^2}, \quad \epsilon = 10^{-8} \quad (9)$$

批次为单元素或标准差为零时 $z(\cdot)$ 返回全零以避免数值退化。各项含义:

- α_{base} : 基础采集 (UCB 或 qNEI), 代理驱动的探索-开发平衡
- Pref_{MC} : 偏好后验的 MC 积分得分 (§6.2)
- Prior : 基于 JSON 配置的专家先验打分 (§6.3)
- VOI : 代理模型后验方差作为信息价值近似 (§6.4)

权重 $\lambda_p, \lambda_k, \lambda_v \geq 0$ 均可 CLI 配置, 默认 $\lambda_p = \lambda_k = 1.0$, $\lambda_v = 0.0$ (关闭)。

6.2 偏好学习与蒙特卡洛效用积分

专家每轮选择执行某一候选而非其余，构成一组典型的成对比较数据。系统使用 BoTorch 的 PairwiseGP [3] 以 Bradley-Terry 模型建模专家效用函数 $u(x)$:

$$P(x_i \succ x_j) = \Phi(u(x_i) - u(x_j)), \quad u \sim \mathcal{GP}(\mathbf{0}, k_{\text{pref}}) \quad (10)$$

Φ 为标准正态 CDF, k_{pref} 为偏好空间上的 ARD Matérn 核。

关键改进 (EI-UU): 依 Astudillo & Frazier [9] 的 Expected Improvement under Utility Uncertainty 框架，不使用偏好后验均值作为点估计，而是对效用后验做 MC 积分：

$$\text{Pref}_{\text{MC}}(x) = \frac{1}{S} \sum_{s=1}^S u^{(s)}(x), \quad u^{(s)} \sim p(u | \mathcal{D}_{\text{pref}}) \quad (11)$$

默认 $S = 16$ 个后验采样，通过重参数化 (`rsample`) 实现。该方法保留效用不确定性信息，避免过早锁定偏差估计。

偏好数据去重: 为防止候选重复导致比较图冗余膨胀，新点写入前做 L_2 近邻查重 (阈值 $\epsilon = 10^{-4}$)，匹配到已有节点时复用索引。

三态偏好支持: 交互界面支持 `winner` / `loser` / `tie` 三种回答。Tie 不写入偏好模型 (PairwiseGP 不原生支持等价标签)，仅作审计记录，`tie_count` 写入实验元数据。

6.3 专家先验编码

领域专家对某些描述符具有先验判断 (例如”最优电位约 -1.0 至 -0.6 V”)。系统通过 JSON 配置将这些知识编码为参数化分布 (高斯或均匀)，采集评估时产生先验打分：

$$\text{Prior}(x) = \sum_{k \in \mathcal{K}} S_k(x_k) \quad (12)$$

$\mathcal{K}$ 为配置了先验的特征子集。高斯先验 $S_k(x_k) = -\frac{(x_k - \mu_k)^2}{2\sigma_k^2}$ (对数密度核)，均匀先验在区间外施加常数惩罚。

先验校验流程 (Prior Predictive Check): `scripts/validate_prior.py --task <name>` 对 JSON 配置执行：(1) 参数合法性校验 ($\sigma > 0$ 、 $\min < \max$)；(2) Monte Carlo 采样检查设计空间覆盖率；(3) 输出结构化 JSON 报告。未通过校验的先验不应进入正式实验。每条记录含 `confidence`、`evidence` 审计字段保证可追溯。工具通过 `--task` 参数从 `TASK_REGISTRY` 取得对应设计域边界，天然支持多体系。

6.4 近似信息价值 (Approximate VOI)

知识梯度 (Knowledge Gradient, KG) [10] 的核心是偏好”信息价值高”的候选。真正的 KG 需要 one-step lookahead 嵌套优化，计算开销极大。作为轻量近似，使用代理模型后验方差作为信息价值代理：

$$\text{VOI}(x) = \text{Var}[f(x)|\mathcal{D}_t] = \sigma_t^2(x) \quad (13)$$

高方差区域的评估最大化后验信息增益，这是 KG 的零阶近似。通过 λ_v 控制权重，默认关闭。

7 偏好探索子循环 (Preference Exploration)

标准 HITL-BO 中偏好信息仅从实验后的候选选择中被动获取。受 Lin et al. [12] PEBO 框架启发，系统引入**偏好探索 (Preference Exploration, PE)** 子循环：在每轮实物实验之前，以零实验代价主动查询专家偏好。

采用**不确定性策略**：从离散候选池中选择偏好模型最不确定、且预测偏好差异最小的 pair——信息量最大。对每对 (x_i, x_j) 计算：

$$\text{Info}(x_i, x_j) = \text{Var}[u(x_i)] + \text{Var}[u(x_j)] - |\mathbb{E}[u(x_i)] - \mathbb{E}[u(x_j)]| \quad (14)$$

得分最高的 B 对 ($B = \text{pe_budget}$, 默认 0 关闭) 依次呈现给专家，每对支持”A 优 / B 优 / Tie” 三种回答。非 tie 直接写入偏好模型，PE 结束后触发偏好 GP 重拟合，再进入正式采集优化。PE 在冷启动时（无偏好模型）退化为随机对选择。

8 多样性感知推荐菜单

受 Astudillo & Frazier [9] ”向决策者呈现菜单而非单点”理念驱动，Top-N 推荐采用贪心子模选择进行多样性重排：

1. 第 1 位：取纯最高采集值候选
2. 后续位：取使 $\hat{\alpha}(x_i) + w_d \cdot \min_{j \in \mathcal{S}} \|x_i - x_j\|_2$ 最大者，其中 $\mathcal{S}$ 为已选集， w_d 为多样性权重 (`--diversity-weight`, 默认 0.5)

这避免了同质化推荐， $w_d = 0$ 退化为纯分数排序， w_d 增大则强化候选间的空间分散。

9 人类在环机制与 KABO 执行流

连续边界寻优得到的连续理想配方点 x_{cont}^* 与读取外部历史离散库得到的候选最佳点 X_{disc}^* 之间，模型未必保证它们对应的物化配置绝对可以在实验室合规组装。此时人工干预（Manual Override）与偏好探索作为控制流汇聚核心介入。

整体流程分为**主循环骨架**（算法 1）与**单轮内层迭代**（算法 2）两部分，后者为前者 FOR 循环体中被调用的子过程 $\text{INNERITERATION}(t, \mathcal{T}, \mathcal{D}_{t-1}, D_{\text{cand}}, \mathcal{M}_{\text{pref}})$ 。

Algorithm 1 KABO 主循环骨架（适用于任意 **TaskBase** 子类）

Require: Task 对象 $\mathcal{T}$ ，总迭代数 T ，初始观测组 $\mathcal{D}_0$ ，候选数据库 D_{cand}

Require: KABO 参数 $\lambda_p, \lambda_k, \lambda_v$ ；PE 预算 B ；先验配置 $\mathcal{P}$

- 1: **Initialize:** $d \leftarrow |\mathcal{T}.\text{feature_columns}|$ ；默认目标取 $\mathcal{T}.\text{default_target}()$ ，用户可覆写采集策略
 - 2: **Phase 1:** 用 RF 回归器从 $\mathcal{D}_0$ 对目标拟合，排序筛选最显著的 K 项作 X_{selected}
 - 3: 加载专家先验 $\mathcal{P}$ 并执行 Prior Predictive Check 校验
 - 4: 初始化偏好模型 $\mathcal{M}_{\text{pref}} \leftarrow \emptyset$
 - 5: **for** $t = 1$ **to** T **do**
 - 6: $(x_{\text{final}}, \mathbf{Y}_{\text{all}}, \mathcal{M}_{\text{pref}}) \leftarrow \text{INNERITERATION}(t, \mathcal{T}, \mathcal{D}_{t-1}, D_{\text{cand}}, \mathcal{M}_{\text{pref}})$
 - 7: $\mathcal{D}_t \leftarrow \mathcal{D}_{t-1} \cup (x_{\text{final}}, \mathbf{Y}_{\text{all}})$
 - 8: **end for**
-

Algorithm 2 INNERITERATION: 单轮 KABO 迭代

Require: 迭代轮数 t , Task $\mathcal{T}$, 历史数据 $\mathcal{D}_{t-1}$, 候选库 D_{cand} , 偏好模型 $\mathcal{M}_{\text{pref}}$

```
1: // Step 0: Preference Exploration (可选)
2: if KABO 模式启用 and  $B > 0$  then
3:   从  $D_{\text{cand}}$  选出  $B$  个最具信息量的候选对
4:   for  $b = 1$  to  $B$  do
5:     向专家展示 pair, 收集回答  $\in \{A, B, \text{Tie}\}$ 
6:     if 非 Tie then
7:       将 winner/loser 写入  $\mathcal{M}_{\text{pref}}$ 
8:     end if
9:   end for
10: 重拟合  $\mathcal{M}_{\text{pref}}$  (PairwiseGP Laplace MLL)
11: end if
12: // Step 1: 构建 KABO 采集函数
13:  $\mathcal{M}_{\text{GP}} \leftarrow \text{Fit}(\mathcal{D}_{t-1}, k_{\text{ARD}})$  // 由 Engine.fit_surrogate 完成
14:  $\alpha_{\text{base}} \leftarrow \text{UCB}(\beta_t)$  或 qNEI
15:  $\alpha_{\text{KABO}} \leftarrow z(\alpha_{\text{base}}) + \lambda_p z(\text{Pref}_{\text{MC}}) + \lambda_k z(\text{Prior}) + \lambda_v z(\text{VOI})$ 
16: // Step 2: 候选优化与多样性推荐
17:  $x_{\text{cont}} \leftarrow \arg \max_{x \in [0,1]^K} \alpha_{\text{KABO}}(x)$ 
18: 评估离散候选  $\hat{Y}_{\text{disc}} \leftarrow \text{Evaluate}(D_{\text{cand}}, \alpha_{\text{KABO}})$ 
19: 按多样性重排推举 Top-N 菜单 (贪心子模)
20: Pre-fill-before-choice: 未被选中的  $d - K$  维用专家值或中点补齐
21: // Step 3: Human Review
22: if 专家选择 tie then
23:    $x_{\text{final}} \leftarrow \text{Rank \#1}$ ; 跳过偏好记录
24: else if 专家选择 manual override then
25:    $x_{\text{final}} \leftarrow x_{\text{manual}}$ ; ( $x_{\text{manual}} \succ$  all Top-N) 写入  $\mathcal{M}_{\text{pref}}$ 
26: else
27:    $x_{\text{final}} \leftarrow x_{\text{chosen}}$ ; 写入偏好对
28: end if
29: // Step 4: Laboratory Execution
30:  $\mathbf{Y}_{\text{all}} \leftarrow \mathcal{T}.\text{prompt\_observation}(\cdot)$  // 或 simulate_observation
31: return ( $x_{\text{final}}, \mathbf{Y}_{\text{all}}, \mathcal{M}_{\text{pref}}$ )
```

值得注意的是两个伪代码中的所有步骤均不涉及体系特定术语: 无论 $\mathcal{T}$ 是 CO2RRTask、TestTask 还是未来的 OERTask、NRRTask, 控制流完全一致, 体系差异仅在 $\mathcal{T}$ 的方法体内表达。

10 案例研究：光催化 CO₂ 还原 (C02RRTask)

10.1 19 描述符 × 7 产物方案

C02RRTask 在 `kabo/task/co2rr.py` 中实现，约 150 行。其特征维度按物化分组：

- 氨基酸 A (4 维): A_pI、A_distance、A_hbond_acceptors、A_hbond_donors
- 氨基酸 B (4 维): B_pI、B_distance、B_hbond_acceptors、B_hbond_donors
- 卟啉 MOF (2 维): MOF_potential、M_CO_binding_energy
- 光敏剂 (2 维): PS_absorption_wavelength、PS_potential
- 溶剂(4 维): Solvent_dielectric、Solvent_hbond_acceptors / donors、CO₂_solubility
- 反应条件 (3 维): H₂O_concentration、Sacrificial_agent_potential、Sacrificial_agent_concentration

产物列包含 CO、HCOOH、CH₄、C₂H₄、CH₃OH、C₂H₅OH、H₂，其中 H₂ 被识别为竞争性 HER 副反应。

10.2 HER 选择性复合目标

C02RRTask.build_training_target 支持 H₂ 惩罚项：当 `h2_penalty_weight > 0` 时，构造 $y_{\text{composite}} = Y_{\text{target}} - w \cdot Y_{H_2}$ 作为代理训练目标，引导优化器偏离 HER 主导区。该机制是 CO₂RR 专有，OER 等其他体系无需暴露——验证了 Task 层封装体系特殊逻辑的合理性。

10.3 产物模拟分布 (Demo 模式)

C02RRTask.simulate_observation 根据 CO₂RR 产物特性设定：目标产物以 GP 训练均值为中心、 0.3σ 为幅度采样；H₂ 在 [2, 15] 均匀分布 (HER 基线范围)；其他产物服从指数分布 (`scale = 2.0`) 模拟痕量副产物。该分布是 CO₂RR 领域的经验先验，不被 Engine 所感知。

11 体系无关性验证：TestTask

为独立验证 KABO 架构的任务解耦性，系统内置最小综合任务 TestTask (位于 `kabo/task/test_task.py`，约 60 行)：

- 特征维: 3 (x1、x2、x3)，单位边界 $[0, 1]^3$

- 产物列：1 (y)
- 训练目标：直接取 y ，无复合项
- 模拟分布：以 GP 均值为中心、 0.5σ 采样单目标

合成数据使用形如 $y = 10 - 5 \sum_k (x_k - \mu_k^*)^2 + \epsilon$ 的平滑单峰函数 ($\mu^* = (0.3, 0.7, 0.5)$)。通过命令

```
python -m kabo --task test --data data/test_data.csv --candidates none \
    --skip-feature-selection --non-interactive --iterations 2 --seed 42
```

可验证：(1) 相同 KABOEngine 实例在 3 维空间上正确拟合；(2) Phase 3 迭代推荐收敛至真实极值附近（GP 学到的 ARD 长度尺度约 0.28/0.39/1.54，正确反映 x_3 对目标响应的相对弱相关）；(3) 全程无体系硬编码泄漏。

12 可追溯性与参数审计

为保证实验结果完全可复现，系统在每次运行结束将所有超参数与配置写入结构化元数据文件 `run_metadata.json`：

- **基础参数**：seed、beta_schedule、beta_trace、acq_strategy
- **KABO 参数**：kabo_mode、lambda_p、lambda_k、lambda_v
- **交互参数**：diversity_weight、pe_budget、tie_count
- **先验参数**：expert_prior_file（含版本追溯）
- **任务参数**：task（记录 task_name()）、selected_features（实际使用的 K 个描述符）

所有参数均在优化器初始化阶段执行严格防呆校验（有限性、非负性、类型检查），异常值在运行前即被拦截。

13 讨论与展望

13.1 任务解耦的工程价值

将 CO₂RR 专用代码重构为任务解耦架构的核心收益体现在三方面：

1. **可扩展性**：新增体系的增量代码量 ~ 50 行，零算法改动；多组实验室可并行各自体系而不互相干扰。

2. **可验证性**: `TestTask` 作为合成基线使 `Engine` 数学逻辑可以在合成数据上独立单元测试, CO_2RR 回归测试可以冻结基线比对。
3. **可维护性**: 体系常量、交互文案、模拟分布隔离在各自 `Task` 文件内, 修改某个体系不会波及其他体系的测试基线。

13.2 潜在扩展方向

- **多目标 Pareto 前沿**: 目前 `Task` 返回标量训练目标, 未来可扩展 `build_training_targets()` 返回向量以支持 multi-objective qEHVI [3]
- **异构特征类型**: 当前 GP 仅处理连续特征, 离散类别特征 (如“溶剂种类”) 可通过 Wang et al. CatBOX 框架 [6] 的谱混合核扩展
- **更深的先验注入**: Mikkola et al. [13] 的先验启发方法可与 JSON 先验编码融合, 支持领域专家以自然语言描述先验

14 结语

本报告构建了从特征解耦裁剪、物理感知映射的高斯代理, 到知识增强贝叶斯优化闭环的完整系统, 并通过任务解耦架构使同一套算法内核支持任意催化体系。相较于原始 HITL-BO 框架, KABO 在四个方面实现了质的提升: (1) 通过 PairwiseGP 偏好学习与 MC 积分将专家交互选择转化为持久化的效用模型; (2) 通过 JSON 参数化先验编码与 Prior Predictive Check 使领域知识的注入可审计、可校验; (3) 通过偏好探索子循环以零实验代价主动增强偏好模型质量; (4) 通过近似 VOI 项引导探索高信息价值区域。四项复合采集函数经在线 z-score 标定后协同工作, 在 CO_2RR 等不确定大搜索面下兼顾开发、探索、偏好与知识价值四重目标。任务解耦层使这套机制得以从 CO_2RR 顺利推广至 OER、NRR、ORR 等同类仿酶催化体系, 成为多成分催化实验与自动化合成间的可迁移驱动支点。

参考文献

- [1] Ding et al., *Efficient and Principled Scientific Discovery through Bayesian Optimization: A Tutorial*. arXiv:2604.01328v3.
- [2] Letham et al., *Constrained Bayesian Optimization with Noisy Experiments*. arXiv:1706.07094v2.
- [3] Balandat et al., *BoTorch: A Framework for Efficient Monte-Carlo Bayesian Optimization*. arXiv:1910.06403v3.
- [4] Wang et al., *Scalable Global Optimization via Local Bayesian Optimization*. arXiv:1910.01739v4.
- [5] Snoek et al., *Practical Bayesian Optimization of Machine Learning Algorithms*. arXiv:1206.2944v2.
- [6] Li et al., *CatBOX: A Categorical-Continuous Bayesian Optimization with Spectral Mixture Kernels for Accelerated Catalysis Experiments*. arXiv:2505.17393v2.
- [7] Author et al., *Multivariate Bayesian Optimization of CoO Nanoparticles for CO₂ Hydrogenation Catalysis*. Journal of the American Chemical Society (2024), DOI: 10.1021/jacs.4c03789.
- [8] Author et al., *Identifying a highly efficient molecular photocatalytic CO₂ reduction system via descriptor-based high-throughput screening*. Nature Catalysis (2025), DOI: 10.1038/s41929-025-01291-z.
- [9] Astudillo & Frazier, *Multi-Attribute Bayesian Optimization under Utility Uncertainty*. arXiv:1911.05934.
- [10] Wu & Frazier, *The Parallel Knowledge Gradient Method for Batch Bayesian Optimization*. arXiv:1606.04414.
- [11] Li et al., *Incorporating Expert Prior in Bayesian Optimisation via Space Warping*. arXiv:2002.11256.
- [12] Lin et al., *Preference Exploration for Efficient Bayesian Optimization with Multiple Outcomes*. arXiv:2203.11382.
- [13] Mikkola et al., *Prior Knowledge Elicitation: The Past, Present, and Future*. arXiv:2112.01380.